本书系统地总结了以现代神经网络语言模型为基础的自然语言生成算法、模型和技术。自然语言生成的基本问题可以归结为"给定上文预测下文"。为了在神经网络模型下"预测下文",需要引入静态词向量、语境化语言表示、条件概率建模,以及参数化的网络模型等新概念与新方法,才有可能实现从传统统计语言建模到神经网络建模,实现从语言文字的符号表示到向量表示的重大转变。语言生成的这种转变深刻地体现了人工智能中,从第一代知识驱动方法到第二代数据驱动方法的计算范式的转变。本书第3章到第7章围绕这种模型和计算范式,从基础模型、优化方法、生成方式和生成机制等多个层面进行了介绍。在基础模型中,介绍了循环神经网络和Transformer网络,并从模型结构和注意力机制等角度分析两者的区别和联系;在优化方法上,介绍了变分编解码器和生成式对抗网络中的优化方法;在生成方式上,除自回归生成方式外,还介绍了前沿的非自回归生成方式。

现有的文本生成模型由于缺乏知识而存在不少缺陷,如生成的内容连贯性差,甚至存在逻辑上矛盾和违背客观世界认知的内容;生成的内容信息量少,前后重复的内容多等。解决这些缺陷的办法是,在语言生成的模型中融入知识。但这项工作面临诸多的挑战,因为传统的知识表示采用符号化方法,在神经网络语言模型中,需要将符号表示转化为低维稠密向量表示,这种转化必然带来语义信息的丢失。而且,知识到自然语言的映射是一对多的关系,非常复杂。如何从大量的领域知识和常识中选择合适的知识融入,也存在很多的困难。本书第8章和第9章在规划和知识融入语言生成机制中,详细讨论了知识驱动与数据驱动相结合的各种可能方案。

自 20 世纪 50 年代人工智能诞生以来,自然语言生成一直是人工智能和自然语言处理 的重要研究领域,并深受人工智能研究流派的影响。20 世纪 60 到 80 年代,符号主义在 第一代人工智能中占主导地位。在语言生成中,采用的是基于规则和传统的机器学习方法,

如由专家系统生成的简单解释,以及从数据库查询中返回的结果编写自然语言答案等,这充分说明符号主义对语言生成的影响。20世纪80到90年代,以连接主义为主线的第二代人工智能崛起,在语言生成中,统计语言模型及前馈神经网络语言模型的提出,改变了语言建模的思路,开启了统计语言建模的新篇章。如今,基于神经网络的语言模型已经占据自然语言生成方法的统治地位。那么,能不能说,自然语言生成已经达到它的终点——到达或接近人类的水平?肯定不是。正如上面指出,目前机器所生成的自然语言与人类相比,还有很大的差距,未来的路还很长。发展第三代人工智能,将知识驱动和数据驱动结合起来,也一定是自然语言生成未来发展的方向。

总之,自然语言生成是人工智能和自然语言处理的重要研究领域。本书是一部以自然语言生成为专题的书籍。它整理、概括和归纳了现有自然语言生成模型、框架和方法,深入思考了这个领域的现状和未来。本书内容丰富,观点清晰,其中所涉及的模型、算法和技术,不仅在自然语言处理中,而且在人工智能中,均具有普适的意义。本书可以作为高等院校计算机科学与技术、人工智能和大数据等相关专业高年级本科生、研究生相关课程的教材,也可作为从事自然语言处理研究和应用的科研和工程技术人员的参考书。

张钹

2020年12月8日于清华园